

Évaluation du raisonnement logique en NLP

Pourquoi FOLIO est adapté au syllogisme
et pourquoi ReClor reste un benchmark incontournable

3 juin 2026

Table des matières

1	Introduction	2
2	FOLIO : un dataset adapté au syllogisme	2
2.1	Qu'est-ce que le syllogisme ?	2
2.2	Présentation de FOLIO	2
2.3	Pourquoi FOLIO est bien adapté au syllogisme	3
2.4	Limites de FOLIO	3
3	ReClor : un benchmark incontournable pour le raisonnement argumen- tatif	4
3.1	Présentation de ReClor	4
3.2	Pourquoi ReClor est intéressant	4
3.3	Limites de ReClor	5
4	Comparaison synthétique	5
5	Conclusion	5

Introduction

L'évaluation de la capacité des modèles de langue à *raisonner* est l'un des défis centraux du traitement automatique du langage naturel (NLP). Deux grandes formes de raisonnement se distinguent : le raisonnement **déductif formel**, dont le syllogisme est l'archétype, et le raisonnement **argumentatif critique**, qui consiste à analyser, renforcer ou affaiblir des arguments exprimés en langage naturel.

Ces deux formes de raisonnement sont complémentaires, et deux datasets se distinguent pour les évaluer : **FOLIO** (Han et al., 2022) pour la logique du premier ordre et le raisonnement déductif, et **ReClor** (Yu et al., 2020) pour le raisonnement argumentatif et critique.

Ce document présente les forces de chacun de ces deux datasets et explique pourquoi leur combinaison offre une évaluation complète des capacités de raisonnement logique des modèles de langue.

FOLIO : un dataset adapté au syllogisme

Qu'est-ce que le syllogisme ?

Le syllogisme est une forme de raisonnement déductif formalisée depuis Aristote. Il consiste à tirer une conclusion à partir de deux prémisses :

*Tous les hommes sont mortels.
Socrate est un homme.
∴ Socrate est mortel.*

Ce type de raisonnement appartient à la **logique du premier ordre** (FOL, *First-Order Logic*), qui permet d'exprimer des quantificateurs (*tous, certains, aucun*) et des relations entre individus. Évaluer si un modèle maîtrise ce type de raisonnement requiert un dataset spécifiquement conçu pour cela.

Présentation de FOLIO

FOLIO (*First-Order Logic Inference and Ontology*) est un dataset introduit par Han et al. (2022) et publié à EMNLP 2024. Il constitue à ce jour le **premier dataset annoté par des experts humains** pour le raisonnement en logique du premier ordre avec des annotations formelles parallèles en FOL.

Structure du dataset

Chaque exemple de FOLIO contient :

- Un ensemble de **prémisses** rédigées en langage naturel
- Une **conclusion** à évaluer
- Une étiquette parmi trois valeurs : **True**, **False**, ou **Unknown**
- Les **formules FOL** correspondantes, vérifiées automatiquement par un moteur d'inférence

FOLIO contient **1 430 exemples** (conclusions uniques) répartis sur 487 ensembles de prémisses.

Pourquoi FOLIO est bien adapté au syllogisme

1. Des annotations formelles vérifiées automatiquement

Contrairement aux datasets annotés uniquement en langage naturel, FOLIO fournit pour chaque exemple une traduction en logique du premier ordre vérifiée par un moteur d'inférence automatique. Cela garantit que les exemples sont **logiquement corrects** et non ambigus, ce qui est indispensable pour évaluer le raisonnement syllogistique.

2. Une construction hybride basée sur le syllogisme

La méthode de construction de FOLIO repose explicitement sur une forme courante de raisonnement logique : **le syllogisme**. Les auteurs utilisent une approche hybride qui combine annotation humaine et génération automatique à partir de structures syllogistiques, garantissant une couverture large et variée des formes de raisonnement déductif.

3. Un langage naturel de haute qualité

Contrairement à d'autres datasets de logique formelle qui utilisent des phrases artificielles et peu naturelles, FOLIO est rédigé par des experts humains à partir d'articles Wikipédia comme sources. Les phrases sont **proches du langage réel**, ce qui permet d'évaluer si les modèles peuvent faire le lien entre expression naturelle et structure logique formelle.

4. Une diversité des profondeurs de raisonnement

FOLIO couvre des chaînes de raisonnement de **profondeurs variées** : certains exemples requièrent une seule inférence directe (proche d'un syllogisme simple), d'autres nécessitent d'enchaîner plusieurs règles logiques. Cela permet de mesurer finement la capacité des modèles à gérer des raisonnements de complexité croissante.

5. Un défi même pour GPT-4

Les expériences menées dans le papier original montrent qu'un sous-ensemble de FOLIO représente un défi pour GPT-4, l'un des modèles les plus puissants disponibles. Des travaux ultérieurs ont montré qu'un modèle DeBERTa-v3 de taille modeste, entraîné sur des données synthétiques de logique, peut surpasser GPT-4 sur ce benchmark, illustrant que **la taille du modèle ne suffit pas** : c'est la capacité de raisonnement formel qui compte.

6. Une double tâche

FOLIO permet d'évaluer deux capacités distinctes :

1. Le **raisonnement en langage naturel** : étant donné les prémisses, la conclusion est-elle vraie, fausse ou indéterminée ?
2. La **traduction NL $\rightarrow$ FOL** : le modèle peut-il traduire correctement une phrase naturelle en formule logique formelle ?

Limites de FOLIO

Malgré ses qualités, FOLIO présente quelques limites à noter :

- Sa taille reste modeste (1 430 exemples), ce qui peut limiter l'entraînement supervisé

- Il se concentre exclusivement sur le raisonnement déductif formel, sans couvrir les formes d’argumentation plus nuancées du langage courant
- Il ne propose pas de mécanisme pour distinguer les exemples biaisés des exemples véritablement difficiles, contrairement à ReClor

ReClor : un benchmark incontournable pour le raisonnement argumentatif

Présentation de ReClor

ReClor (*Reading Comprehension dataset requiring logical reasoning*) est introduit par Yu et al. (2020) et publié à ICLR 2020. Il est constitué de **6 138 questions** de raisonnement logique extraites d’examens standardisés d’entrée en école supérieure (GMAT et LSAT).

Chaque exemple contient :

- Un **contexte** (passage argumentatif court, 73 tokens en moyenne)
- Une **question** portant sur la logique du passage
- **4 options de réponse**, dont une seule est correcte

Pourquoi ReClor est intéressant

1. Une source de haute qualité

Les questions sont issues d’examens conçus par des experts pour évaluer précisément la capacité de raisonnement logique de candidats à des études supérieures. Cette origine garantit une difficulté et une rigueur qu’un crowdsourcing classique ne peut pas reproduire.

2. Une taxonomie fine de 17 types de raisonnement

ReClor couvre 17 types de raisonnement argumentatif distincts, parmi lesquels :

Type	Proportion
Identifier une faille	11,7%
Hypothèses nécessaires	11,4%
Affaiblir un argument	11,3%
Renforcer un argument	9,4%
Expliquer ou résoudre	8,4%
Principe	6,5%
Autres	7,3%

TABLE 1 – Principaux types de raisonnement dans ReClor

3. Le dispositif anti-biais : EASY vs HARD

C’est la contribution méthodologique la plus originale de ReClor. Les auteurs ont identifié que les modèles peuvent exploiter des **biais statistiques** dans les options de réponse pour trouver la bonne réponse sans lire le contexte ni la question.

Pour détecter ces biais, ils entraînent plusieurs modèles (GPT, GPT-2, BERT, XLNet, RoBERTa) en leur donnant **uniquement les options de réponse**. Les exemples correctement résolus sans contexte forment le **set EASY** (biaisé), les autres forment le **set HARD** (non biaisé).

Les résultats révèlent une dichotomie frappante :

Modèle	EASY (%)	HARD (%)
Chance (aléatoire)	25,0	25,0
RoBERTa _{LARGE}	75,5	40,0
XLNet _{LARGE}	75,7	40,5
Humains (étudiants)	57,1	67,2

TABLE 2 – Performance sur les sets EASY et HARD de ReClor

Les modèles s’effondrent sur HARD, atteignant à peine mieux que le hasard (25%), tandis que les humains restent performants. Cela prouve que les modèles **mémorisent des patterns** plutôt que de réellement raisonner.

4. Des options riches en contenu

Avec une longueur moyenne de **20,6 tokens par option** (contre 5,3 pour RACE ou 4,2 pour ARC), les options de ReClor sont de véritables arguments, ce qui empêche les raccourcis basés sur la longueur ou la simplicité des formulations.

5. L’efficacité du transfert d’apprentissage

ReClor montre également l’intérêt du transfert d’apprentissage : en préentraînant les modèles sur RACE avant de les affiner sur ReClor, les performances sur le set HARD augmentent significativement, suggérant que l’exposition à des raisonnements similaires améliore la capacité logique des modèles.

Limites de ReClor

- ReClor n’évalue pas le raisonnement déductif formel (syllogisme, logique du premier ordre)
- Le dataset est relativement petit (6 138 exemples) par rapport à RACE (97 687 exemples)
- Les questions portent sur un registre académique et argumentatif, moins représentatif des usages courants du langage

Comparaison synthétique

Conclusion

FOLIO et ReClor sont deux datasets complémentaires qui évaluent des formes différentes mais également importantes du raisonnement logique.

FOLIO est le choix naturel pour évaluer le raisonnement **syllogistique et déductif formel**. Ses annotations en logique du premier ordre, vérifiées automatiquement, garan-

Critère	FOLIO	ReClor
Type de raisonnement	Déductif formel (FOL)	Argumentatif critique
Adapté au syllogisme	Oui	Partiellement
Taille	1 430 exemples	6 138 exemples
Source	Experts humains + Wikipedia	GMAT / LSAT
Annotations formelles	Oui (FOL vérifiées)	Non
Détection de biais	Non	Oui (EASY/HARD)
Diversité des types	Profondeurs variées	17 types distincts
Difficulté pour GPT-4	Oui	Oui (set HARD)

TABLE 3 – Comparaison entre FOLIO et ReClor

tissent la rigueur des exemples, et son langage naturel de qualité permet d’évaluer si les modèles font réellement le lien entre expression naturelle et structure logique.

ReClor est quant à lui incontournable pour évaluer le raisonnement **argumentatif et critique**, tel qu’il s’exprime dans des textes complexes. Son dispositif EASY/HARD est une contribution méthodologique majeure qui permet de distinguer les modèles qui raisonnent vraiment de ceux qui exploitent des biais statistiques.

Pour une évaluation complète des capacités de raisonnement logique d’un modèle, l’utilisation combinée de ces deux datasets est recommandée.

Références

- Han, S. et al. (2022). *FOLIO : Natural Language Reasoning with First-Order Logic*. EMNLP 2024.
- Yu, W. et al. (2020). *ReClor : A Reading Comprehension Dataset Requiring Logical Reasoning*. ICLR 2020.
- Clark, P. et al. (2020). *RuleTaker : Transformers as Soft Reasoners over Language*. IJCAI 2020.
- Saparov, A. & He, H. (2023). *Language Models Are Greedy Reasoners : A Systematic Formal Analysis of Chain-of-Thought*. ICLR 2023.