

Rapport hebdomadaire : validation expérimentale sur le corpus Rhapsodie

TROMBATI Mohamed

Semaine du 13 au 17 juillet

1 Introduction

Le rapport de la semaine précédente a mis en évidence la nécessité de stabiliser l'évaluation de mes modèles de segmentation prosodique via un protocole multi-seeds sur Common Voice (CV). Cependant, une limite conceptuelle majeure persistait : les étiquettes de référence de Common Voice sont issues d'un système de détection automatique des pauses acoustiques, constituant un proxy bruité et potentiellement biaisé par les artefacts de ce corpus (lecture de phrases isolées, pauses de respiration).

L'objectif de cette semaine était de confronter les représentations apprises sur Common Voice à une véritable vérité terrain humaine et experte. Pour ce faire, j'ai mis en œuvre un protocole d'évaluation cross-corpus en mode *zero-shot* (sans aucun ré-entraînement) sur le corpus **Rhapsodie**. Ce rapport détaille la tâche de segmentation prosodique sous-jacente, justifie scientifiquement le choix de Rhapsodie au regard de la littérature récente, et analyse comparativement les performances des modèles selon deux modes de détection de pics : *frozen* (seuil configuré sur CV) et *oracle* (optimisation de seuil directement sur Rhapsodie).

2 La tâche de segmentation prosodique et le rôle de Rhapsodie

2.1 Segmentation prosodique basée sur les pauses : un proxy bruité

La tâche de segmentation automatique consiste à identifier des frontières prosodiques dans le signal de parole continu. Lors de la phase d'entraînement sur Common Voice, le modèle apprend à prédire une fonction continue dont les pics correspondent aux pauses acoustiques automatiques. Or, la littérature en phonétique montre qu'une pause physique ne coïncide pas systématiquement avec une frontière prosodique linguistique (et réciproquement). L'évaluation intra-corpus court donc le risque de sur-apprendre des caractéristiques acoustiques propres au silence ou au style de lecture mécanique de Common Voice, sans capturer la structure prosodique sous-jacente du français parlé.

2.2 Ancrage méthodologique dans l'état de l'art

Pour surmonter cette limite, ma démarche s'appuie directement sur un précédent méthodologique fort proposé par Marie Kunešová et Markéta Rezáčková dans leur article intitulé « *Detection of Prosodic Boundaries in Speech Using Wav2Vec 2.0* ». Dans leur travail sur la langue tchèque, les autrices déploient un pipeline basé sur un modèle T5 d'abord pré-entraîné sur le dataset *LibriSpeech* (LS), dont les frontières prosodiques sont labellisées par segmentation automatique et donc bruitées. Elles procèdent ensuite à une validation et une adaptation sur *NRS*, un corpus réduit mais méticuleusement annoté à la main par des experts phonéticiens.

Je transpose exactement ce paradigme (Pipeline LS → NRS) à mon cadre de travail (Pipeline Common Voice → Rhapsodie). Le corpus Rhapsodie (3h de parole spontanée et planifiée, monologues et dialogues) bénéficie d'une annotation prosodique experte en unités intonatives majeures et mineures. Il joue ici le rôle de filtre de qualité phonétique absolue : si les encodeurs SSL (Pantagruel

et LeBenchmark) ont capté un signal prosodique généralisable, ils doivent être capables de s’aligner sur les annotations de Rhapsodie sans y être entraînés.

3 Protocole expérimental et métriques

L’évaluation *zero-shot* a été menée sur les 57 échantillons de Rhapsodie ($n = 57$) en gelant les encodeurs et les têtes de prédiction optimisées sur Common Voice pour les trois initialisations (seeds 42, 123, 2024). Deux configurations de recherche de seuil (*peak picking*) ont été testées :

- **Mode Frozen** : Utilisation stricte des paramètres de détection optimisés sur Common Voice (vrai test de généralisation aveugle).
- **Mode Oracle** : Balayage de la courbe précision-rappel directement sur Rhapsodie via l’argument `prominence_sweep` pour identifier la borne supérieure théorique des performances du modèle après recalibration du seuil.

4 Analyse des résultats expérimentaux

Le tableau 1 synthétise les F1-scores et les intervalles de confiance à 95 % obtenus pour chaque modèle, chaque seed et selon les deux modes de seuillage.

Modèle et Initialisation	Mode Frozen (Seuil gelé)		Mode Oracle (Seuil optimisé)	
	F1-score	IC 95 %	F1-score	IC 95 %
<i>Pantagruel-B-1K</i>				
seed = 42	0.4603	[0.3904, 0.5352]	0.4860	[0.4144, 0.5582]
seed = 123	0.4328	[0.3639, 0.5054]	0.4648	[0.3951, 0.5375]
seed = 2024	0.4347	[0.3657, 0.5070]	0.4751	[0.4047, 0.5482]
Moyenne $\pm$ écart-type	0.4426 $\pm$ 0.0154	–	0.4753 $\pm$ 0.0106	–
<i>Pantagruel-B-14K</i>				
seed = 42	0.4158	[0.3434, 0.4901]	0.4494	[0.3761, 0.5258]
seed = 123	0.4061	[0.3307, 0.4801]	0.4495	[0.3767, 0.5267]
seed = 2024	0.4445	[0.3766, 0.5136]	0.4793	[0.4099, 0.5500]
Moyenne $\pm$ écart-type	0.4221 $\pm$ 0.0200	–	0.4594 $\pm$ 0.0172	–
<i>Pantagruel-L-14K</i>				
seed = 42	0.3216	[0.2636, 0.3868]	0.3506	[0.2918, 0.4169]
seed = 123	0.2617	[0.2018, 0.3204]	0.3031	[0.2493, 0.3630]
seed = 2024	0.2762	[0.2159, 0.3410]	0.3330	[0.2763, 0.3985]
Moyenne $\pm$ écart-type	0.2865 $\pm$ 0.0313	–	0.3289 $\pm$ 0.0240	–
<i>LeBenchmark-w2v-B-1k</i>				
seed = 42	0.3459	[0.2729, 0.4195]	0.3906	[0.3159, 0.4639]
seed = 123	0.3976	[0.3196, 0.4736]	0.4477	[0.3769, 0.5206]
seed = 2024	0.3152	[0.2410, 0.3882]	0.3460	[0.2701, 0.4193]
Moyenne $\pm$ écart-type	0.3529 $\pm$ 0.0416	–	0.3948 $\pm$ 0.0510	–
<i>LeBenchmark-w2v-L-7k</i>				
seed = 42	0.3886	[0.3164, 0.4646]	0.4300	[0.3534, 0.5059]
seed = 123	0.4000	[0.3287, 0.4701]	0.4564	[0.3856, 0.5292]
seed = 2024	0.3316	[0.2614, 0.4069]	0.3694	[0.2981, 0.4446]
Moyenne $\pm$ écart-type	0.3734 $\pm$ 0.0367	–	0.4186 $\pm$ 0.0446	–

TABLE 1 – Résultats de l’évaluation cross-corpus (F1-score) sur Rhapsodie ($n = 57$).

4.1 Un paradoxe majeur : l’effondrement de LeBenchmark et l’envolée de Pantagruel -B

La comparaison directe avec les résultats de la semaine passée (obtenus sur le test set interne de Common Voice) révèle un phénomène particulièrement frappant et contre-intuitif.

Sur Common Voice, les architectures **LeBenchmark** dominaient largement le protocole, affichant un F1 moyen de 0.3773 (L-7k) et 0.3710 (B-1k), tandis que les variantes **Pantagruel-B** stagnaient en retrait (entre 0.3419 et 0.3544).

Lors du transfert sur Rhapsodie (Mode Frozen), **la tendance s’inverse totalement** :

- **Pantagruel-B-1K** réalise un saut de performance spectaculaire, passant d’un F1 de 0.3419 sur ses données d’entraînement à un F1 moyen de **0.4426 ± 0.0154** en zero-shot, atteignant même 0.4603 sur la seed 42.
- À l’inverse, **LeBenchmark-w2v-B-1k** régresse significativement, chutant à un F1 moyen de 0.3529, accompagné d’une instabilité critique d’une seed à l’autre (écart-type élevé de 0.0416).
- Le modèle **Pantagruel-L-14K**, pourtant performant sur CV (0.3439), s’effondre littéralement sur Rhapsodie avec un score de **0.2865 ± 0.0313** .

Ce paradoxe s’explique par la nature des représentations apprises. **LeBenchmark** et **Pantagruel-L** semblent avoir sévèrement *overfitted* sur les propriétés acoustiques brutes des pauses automatisées de Common Voice (le bruit des labels). Confrontés à de la parole spontanée et à une annotation humaine structurée (Rhapsodie), ils échouent à généraliser. En revanche, les modèles légers **Pantagruel-B** (1K et 14K) font preuve d’une robustesse remarquable : ils ont extrait des propriétés phonétiques profondes de la prosodie du français qui s’alignent naturellement avec les choix des phonéticiens experts.

4.2 L’apport du mode Oracle : une calibration nécessaire

L’activation du mode *Oracle* (Tableau 1, colonnes de droite) engendre une progression systématique des performances pour l’ensemble des configurations. **Pantagruel-B-1K** culmine à un F1 moyen de **0.4753**, et **LeBenchmark-w2v-L-7k** remonte à 0.4186.

Cela démontre que le signal continu prédit par les modèles contient bien l’information prosodique pertinente, mais que la dynamique physique des coupures (le seuil de *prominence*) varie fortement d’un corpus à l’autre. Une simple recalibration non supervisée du seuil sur le domaine cible suffit à débloquer un gain substantiel de ≈ 3 à 4 points de F1 sans toucher aux poids du réseau.

5 Conclusion

La bascule vers le corpus Rhapsodie valide de manière éclatante la pertinence de la stratégie adoptée. Malgré la faiblesse apparente des scores initiaux sur Common Voice, l’évaluation de cette semaine prouve que les modèles en particulier **Pantagruel-B-1K** ($F1 = 0.4426$ en frozen, 0.4753 en oracle) capturent de réelles structures prosodiques humaines, dépassant les artefacts des pauses automatiques.

5.1 Perspectives

- L’évaluation des modèles multi-modaux de la famille Pantagruel
- L’évaluation Frame-Wise (Purity/Coverage) : Implémenter cette métrique continue pour vérifier si l’effondrement de certains modèles (Pantagruel-L) est lié à un décalage temporel systématique plutôt qu’à une incapacité à détecter la frontière.