

Rapport hebdomadaire : évaluation des modèles multimodaux Pantagruel-Speech-Text sur les deux corpus Common Voice et Rhapsodie

TROMBATI Mohamed

du 20 juillet au 27 juillet

1 Introduction

Les deux rapports précédents ont établi, d’une part, la robustesse multi-seeds des cinq encodeurs unimodaux (Pantagruel-B-1K, Pantagruel-B-14K, Pantagruel-L-14K, LeBenchmark-w2v-B-1k, LeBenchmark-w2v-L-7k) sur le test set Common Voice, et d’autre part, leur capacité de généralisation *zero-shot* sur le corpus Rhapsodie, avec un résultat marquant : les modèles **Pantagruel-B** (légers) généralisent nettement mieux que les architectures **LeBenchmark** et que le modèle **Pantagruel-L-14K**, malgré des scores plus modestes sur Common Voice.

Cette semaine, l’objectif était de tester si l’ajout d’une modalité textuelle à l’encodeur apporte un bénéfice à la tâche de segmentation prosodique. Deux nouveaux modèles multimodaux de la famille Pantagruel ont donc été entraînés et évalués selon le même protocole que les semaines précédentes :

- **Pantagruel-Speech-Text-B-1K-v0**
- **Pantagruel-Speech-Text-B-1K**

Les deux modèles partagent le même encodeur de base (B-1K) mais diffèrent par leur variante d’intégration texte-parole. Chaque modèle a été ré-entraîné avec **trois seeds (42, 123, 2024)**, selon le protocole désormais habituel (cache d’embeddings, labels gaussiens, tête Conv1D + BiLSTM, arrêt anticipé sur la validation loss), puis évalué (i) sur le test set Common Voice et (ii) en *zero-shot* sur Rhapsodie, en mode *frozen* et en mode *oracle*.

2 Résultats sur Common Voice (corpus d’entraînement)

Le tableau 1 présente la moyenne et l’écart-type (des 3 seeds) de la précision, du rappel et du F1-score des deux modèles multimodaux sur les test set Common Voice, replacés dans le tableau des cinq modèles unimodaux évalués la semaine précédente.

Modèle	Précision	Recall	F1-score
<i>Pantagruel-B-1K</i>	0.3382 ± 0.0028	0.3670 ± 0.0060	0.3419 ± 0.0027
<i>Pantagruel-B-14K</i>	0.3507 ± 0.0006	0.3790 ± 0.0095	0.3544 ± 0.0042
<i>Pantagruel-L-14K</i>	0.3421 ± 0.0056	0.3678 ± 0.0188	0.3439 ± 0.0108
Pantagruel-Speech-Text-B-1K-v0	0.3438 ± 0.0034	0.3774 ± 0.0062	0.3497 ± 0.0046
Pantagruel-Speech-Text-B-1K	0.3460 ± 0.0013	0.3890 ± 0.0023	0.3562 ± 0.0006
<i>LeBenchmark-w2v-B-1k</i>	0.3626 ± 0.0035	0.3989 ± 0.0064	0.3710 ± 0.0046
<i>LeBenchmark-w2v-L-7k</i>	0.3667 ± 0.0043	0.4088 ± 0.0026	0.3773 ± 0.0025

TABLE 1 – Moyenne et écart-type (3 seeds) des métriques sur le test set Common Voice. Les deux modèles multimodaux évalués cette semaine apparaissent en gras.

Sur Common Voice, l’ajout de la modalité texte procure un gain net par rapport à l’encodeur **Pantagruel-B-1K** purement audio ($F1 = 0.3419$) : **Pantagruel-Speech-Text-B-1K-v0** atteint

0.3497 et **Pantagruel-Speech-Text-B-1K** atteint 0.3562, ce dernier se rapprochant du meilleur modèle Pantagruel unimodal (**Pantagruel-B-14K**, 0.3544). **Pantagruel-Speech-Text-B-1K** est également remarquablement stable d’une seed à l’autre (écart-type de F1 de 0.0006, le plus faible de tous les modèles testés à ce jour, toutes familles confondues). Les deux variantes multimodales restent cependant en retrait par rapport aux deux modèles **LeBenchmark** (0.3710 et 0.3773).

2.1 Analyse d’erreurs

L’analyse d’erreurs par exemple (`mean_f1`) confirme ce classement : **Pantagruel-Speech-Text-B-1K-v0** obtient un F1 moyen par exemple de 0.3489, 0.3442 et 0.3553 selon la seed (42, 123, 2024), tandis que **Pantagruel-Speech-Text-B-1K** obtient 0.3554, 0.3563 et 0.3568 respectivement ce qui montre un profil nettement plus stable, cohérent avec le faible écart-type global du modèle.

Plusieurs exemples difficiles identifiés la semaine précédente pour les cinq modèles unimodaux réapparaissent parmi les pires cas des deux modèles multimodaux, notamment les indices 66, 629, 785, 4890, 173 et 218. En particulier, l’exemple d’indice 66 qui échouait déjà systématiquement (F1 nul) pour les cinq modèles unimodaux échoue également pour **Pantagruel-Speech-Text-B-1K-v0** (seed 2024) et pour **Pantagruel-Speech-Text-B-1K** (seeds 42, 123 et 2024). Ce recoupement renforce l’hypothèse déjà formulée : l’échec sur ces exemples précis tient probablement à la qualité du label de référence (bruit du système de détection automatique des pauses) plutôt qu’au choix ou à la modalité de l’encodeur, puisqu’il persiste même avec l’ajout de la modalité textuelle.

3 Résultats en généralisation *zero-shot* sur Rhapsodie

Les mêmes checkpoints (3 seeds, gelés) ont ensuite été évalués sans ré-entraînement sur les 57 échantillons du corpus Rhapsodie, selon les deux modes de seuillage définis la semaine précédente : *frozen* (seuil configuré sur Common Voice) et *oracle* (seuil qui a été optimisé directement sur Rhapsodie).

Modèle et Initialisation	Mode Frozen		Mode Oracle	
	F1-score	IC 95 %	F1-score	IC 95 %
<i>Pantagruel-Speech-Text-B-1K-v0</i>				
seed = 42	0.3898	[0.3174, 0.4654]	0.4238	[0.3483, 0.4993]
seed = 123	0.4117	[0.3384, 0.4857]	0.4529	[0.3829, 0.5270]
seed = 2024	0.4031	[0.3253, 0.4831]	0.4349	[0.3530, 0.5151]
Moyenne $\pm$ écart-type	0.4015 $\pm$ 0.0110	–	0.4372 $\pm$ 0.0147	–
<i>Pantagruel-Speech-Text-B-1K</i>				
seed = 42	0.3613	[0.2956, 0.4326]	0.3967	[0.3293, 0.4693]
seed = 123	0.3491	[0.2781, 0.4207]	0.4032	[0.3272, 0.4782]
seed = 2024	0.3374	[0.2633, 0.4131]	0.3885	[0.3161, 0.4653]
Moyenne $\pm$ écart-type	0.3493 $\pm$ 0.0120	–	0.3961 $\pm$ 0.0074	–

TABLE 2 – Résultats de l’évaluation cross-corpus (F1-score) sur Rhapsodie ($n = 57$) pour les deux modèles multimodaux.

Pour situer ces résultats, le tableau 3 rappelle les scores obtenus la semaine précédente par les cinq modèles unimodaux sur Rhapsodie.

3.1 La modalité texte n’apporte pas le même bénéfice en généralisation

Le contraste avec les résultats de Common Voice est frappant. Sur Common Voice, les deux modèles multimodaux se classaient devant **Pantagruel-B-1K** et proches du meilleur modèle Pantagruel unimodal. Sur Rhapsodie en revanche, la hiérarchie s’inverse partiellement :

- **Pantagruel-Speech-Text-B-1K-v0** obtient 0.4015 ± 0.0110 en frozen et 0.4372 ± 0.0147 en oracle, un résultat honorable, supérieur à **LeBenchmark-w2v-B-1k** et très supérieur à

Modèle	Frozen (F1)	Oracle (F1)
Pantagruel-B-1K	0.4426 ± 0.0154	0.4753 ± 0.0106
Pantagruel-B-14K	0.4221 ± 0.0200	0.4594 ± 0.0172
Pantagruel-L-14K	0.2865 ± 0.0313	0.3289 ± 0.0240
LeBenchmark-w2v-B-1k	0.3529 ± 0.0416	0.3948 ± 0.0510
LeBenchmark-w2v-L-7k	0.3734 ± 0.0367	0.4186 ± 0.0446

TABLE 3 – Rappel des résultats des modèles unimodaux sur Rhapsodie (rapport de la semaine du 13 au 17 juillet).

Pantagruel-L-14K, mais **inférieur** aux deux modèles Pantagruel unimodaux purement audio (Pantagruel-B-1K : $0.4426/0.4753$; Pantagruel-B-14K : $0.4221/0.4594$).

- Pantagruel-Speech-Text-B-1K (variante de fusion la plus aboutie, et la meilleure des deux sur Common Voice) s’effondre comparativement sur Rhapsodie, avec seulement 0.3493 ± 0.0120 en frozen et 0.3961 ± 0.0074 en oracle, un niveau proche de LeBenchmark-w2v-B-1k, très en retrait par rapport aux versions unimodales Pantagruel-B.

Ce résultat est à rapprocher directement du constat du rapport précédent : les modèles qui exploitaient le mieux les propriétés acoustiques brutes de Common Voice (ici, la variante multimodale la plus stable et la plus performante sur CV) sont aussi ceux qui généralisent le moins bien à une annotation prosodique experte et à de la parole spontanée. La modalité textuelle, pourrait introduire un biais supplémentaire propre à ce corpus qui ne se transfère pas à la structure prosodique de Rhapsodie. Il est notable que c’est la variante -v0, pourtant présentée comme préliminaire, qui généralise le mieux des deux modèles multimodaux, un peu à l’image de la seed favorable observée pour Pantagruel-L-14K la semaine précédente — même si ici l’écart entre les deux variantes est cohérent sur les trois seeds et ne semble donc pas être un simple effet d’initialisation.

3.2 L’apport du mode Oracle

Comme pour les modèles unimodaux, le passage en mode *oracle* améliore systématiquement les deux modèles multimodaux, avec un gain de $+0.036$ point de F1 pour Pantagruel-Speech-Text-B-1K-v0 et de $+0.047$ pour Pantagruel-Speech-Text-B-1K. Cela confirme que le signal continu prédit reste informatif dans les deux cas, mais que le seuil de détection des frontières optimisé sur Common Voice n’est pas directement transférable à Rhapsodie, un constat désormais robuste sur les sept modèles évalués (cinq unimodaux, deux multimodaux).

4 Discussion

eux enseignements principaux se dégagent de cette semaine. Premièrement, un pré-entraînement multimodal (audio et texte) de l’encodeur améliore effectivement la segmentation prosodique *dans le domaine d’entraînement* (Common Voice), y compris lorsque seule l’audio est fournie à la tâche : la variante Pantagruel-Speech-Text-B-1K atteint même le F1 le plus stable de toute l’étude. Deuxièmement, et plus important pour l’objectif final du projet, ce bénéfice ne se transfère pas à l’identique lors du passage *zero-shot* sur Rhapsodie : les encodeurs multimodaux restent au mieux comparables aux meilleurs modèles unimodaux Pantagruel-B, sans les dépasser, et l’un d’eux (Pantagruel-Speech-Text-B-1K) perd une part significative de sa capacité de généralisation.

Ce résultat nuance la conclusion optimiste du rapport précédent selon laquelle les encodeurs Pantagruel-B captent une structure prosodique intrinsèquement transférable : le pré-entraînement multimodal, qui améliore a priori la richesse de la représentation apprise, ne suffit pas à renforcer cette généralisation et peut même la dégrader selon la version considérée. Cela suggère que le gain de généralisation observé sur les modèles Pantagruel-B purement audio tient spécifiquement aux propriétés acoustiques apprises pendant leur pré-entraînement, et que l’exposition additionnelle au

texte pendant le pré-entraînement multimodal n’apporte pas nécessairement une représentation audio plus robuste au changement de corpus, même si elle en améliore la performance dans le domaine d’entraînement.

5 Conclusion

Les deux nouveaux modèles de la famille Pantagruel, dotés d’un encodeur pré-entraîné conjointement sur de la parole et du texte, confirment l’intérêt de ce pré-entraînement multimodal sur le corpus d’entraînement Common Voice, avec un net avantage pour **Pantagruel-Speech-Text-B-1K** ($F1 = 0.3562 \pm 0.0006$) alors même que, comme pour les modèles unimodaux, seule l’audio est fournie en entrée de la tâche de segmentation. Ce bénéfice ne se maintient toutefois pas pleinement lors du transfert *zero-shot* vers Rhapsodie : les deux versions multimodales (0.4015 et 0.3493 en frozen, 0.4372 et 0.3961 en oracle) restent en retrait par rapport aux meilleurs modèles Pantagruel unimodaux (0.4426 et 0.4753 pour **Pantagruel-B-1K**). L’analyse d’erreurs confirme par ailleurs la récurrence d’un petit ensemble d’exemples systématiquement mal segmentés (notamment l’indice 66), indépendamment du type d’encodeur (unimodal ou multimodal), ce qui continue de pointer vers une limite du protocole de labellisation plutôt que vers un défaut spécifique des modèles.