

Rapport hebdomadaire : robustesse multi-seeds et analyse d'erreurs

TROMBATI Mohamed

Semaine du 06 au 10 juillet

1 Introduction

Le rapport de la semaine précédente comparait les modèles Pantagruel et LeBenchmark après fine-tuning d'une tête de segmentation prosodique, sur la base d'un seul entraînement par modèle. À la lecture de ces résultats, l'objectif de cette semaine était de :

- vérifier la robustesse des écarts observés entre modèles en relançant les entraînements avec d'autres initialisations (seeds) ;
- se rapprocher davantage des données en analysant précisément les cas d'échec du système, en particulier les faux positifs et les faux négatifs, afin d'en comprendre l'origine.

Ce rapport présente les résultats obtenus suite à ces deux remarques : (i) un ré-entraînement complet des cinq modèles avec trois seeds différentes (42, 123, 2024) et une évaluation finale sur le split de test pour chaque configuration, et (ii) une analyse d'erreurs systématique sur le split de test à l'aide d'un script dédié (`analyze_errors`), portant sur les exemples les moins bien segmentés par chaque modèle.

2 Méthodologie mise à jour

2.1 Entraînements multi-seeds

Les cinq modèles étudiés la semaine précédente (`Pantagruel-B-1K`, `Pantagruel-B-14K`, `Pantagruel-L-14K`, `LeBenchmark-w2v-B-1k`, `LeBenchmark-w2v-L-7k`) ont été ré-entraînés à l'identique, en ne changeant que la seed d'initialisation (42, 123, 2024). Le protocole reste inchangé par ailleurs : même cache d'embeddings, mêmes labels gaussiens, même tête de segmentation Conv1D + BiLSTM, même critère d'arrêt anticipé sur la validation loss.

Pour chaque modèle, les trois checkpoints obtenus (un par seed) ont été évalués indépendamment sur le split de test. Les résultats sont ensuite résumés par la moyenne et l'écart-type des trois runs, ce qui permet de quantifier la variance liée à l'initialisation plutôt que de se fier à un seul run comme la semaine précédente.

2.2 Analyse d'erreurs

Un script d'analyse d'erreurs (`scripts.analyze_errors`) a été exécuté sur le split de test pour chacun des cinq modèles (checkpoint de la seed 42). Pour chaque exemple, il calcule un F1 au niveau de l'exemple ainsi que le nombre de faux positifs (fp, frontières prédites sans correspondance dans la référence) et de faux négatifs (fn, frontières de référence non retrouvées). Les résultats complets sont exportés en CSV (5000 exemples par modèle) et les dix exemples les plus mal segmentés sont listés pour chaque modèle.

3 Robustesse des résultats sur le test set

Le tableau 1 résume, pour chaque modèle, la moyenne et l'écart-type de la précision, du rappel et du F1-score sur le test set, calculés sur les trois seeds.

Modèle	Précision	Recall	F1-score
Pantagruel-B-1K	0.3382 ± 0.0028	0.3670 ± 0.0060	0.3419 ± 0.0027
Pantagruel-B-14K	0.3507 ± 0.0006	0.3790 ± 0.0095	0.3544 ± 0.0042
Pantagruel-L-14K	0.3421 ± 0.0056	0.3678 ± 0.0188	0.3439 ± 0.0108
LeBenchmark-w2v-B-1k	0.3626 ± 0.0035	0.3989 ± 0.0064	0.3710 ± 0.0046
LeBenchmark-w2v-L-7k	0.3667 ± 0.0043	0.4088 ± 0.0026	0.3773 ± 0.0025

TABLE 1 – Moyenne et écart-type (3 seeds) des métriques sur le test set.

3.1 Le classement des modèles change par rapport à la semaine précédente

La semaine précédente, avec un seul run, **LeBenchmark-w2v-B-1k** obtenait le meilleur F1 (0.3695), devant **LeBenchmark-w2v-L-7k**. En moyenne sur trois seeds, c'est en réalité **LeBenchmark-w2v-L-7k** qui obtient le meilleur F1 (0.3773 ± 0.0025), légèrement devant **LeBenchmark-w2v-B-1k** (0.3710 ± 0.0046). Le run isolé de la semaine précédente pour **LeBenchmark-w2v-B-1k** (seed 42, $F1 = 0.3726$) se trouvait donc dans la partie haute de sa distribution, ce qui a probablement suffi à inverser le classement observé entre les deux modèles.

Ce résultat illustre directement qu'un écart de F1 de l'ordre de 0.01 entre deux modèles, mesuré sur un seul run, n'est pas suffisant pour conclure qu'un modèle est réellement meilleur qu'un autre. Sur les cinq modèles, l'écart-type du F1 sur trois seeds varie entre 0.0025 (**LeBenchmark-w2v-L-7k**) et 0.0108 (**Pantagruel-L-14K**), ce qui représente déjà une part non négligeable des écarts observés entre modèles voisins.

3.2 Modèles stables et modèles sensibles à l'initialisation

LeBenchmark-w2v-L-7k est à la fois le meilleur modèle en moyenne et le plus stable (écart-type de F1 de 0.0025 seulement), ce qui renforce la confiance dans ce résultat. À l'inverse, **Pantagruel-L-14K** est le modèle le plus sensible à la seed d'initialisation (écart-type de 0.0108, soit environ quatre fois celui de **LeBenchmark-w2v-L-7k**), et son rappel varie de 0.3459 à 0.3918. Le bon score obtenu par **Pantagruel-L-14K** la semaine précédente ($F1 = 0.3550$ pour la seed 42) correspond en fait à sa meilleure seed sur les trois testées ; en moyenne, **Pantagruel-L-14K** (0.3439) reste proche de **Pantagruel-B-1K** (0.3419) et n'apparaît plus clairement comme le meilleur modèle Pantagruel.

Parmi les modèles Pantagruel, **Pantagruel-B-14K** reste le plus stable (écart-type de F1 de 0.0042) et obtient désormais le meilleur F1 moyen (0.3544), ce qui est cohérent avec l'observation faite en validation la semaine précédente.

4 Analyse des erreurs

L'analyse d'erreurs a été réalisée sur le split de test pour les cinq modèles (checkpoint seed 42). Le tableau 2 compare le F1 moyen par exemple (`mean_f1`, moyenne des F1 calculés exemple par exemple) au F1 global rapporté la semaine précédente pour la même seed.

Les deux métriques sont proches pour la plupart des modèles, mais un écart plus marqué apparaît pour **LeBenchmark-w2v-L-7k** (0.3793 en F1 global contre 0.3538 en moyenne par exemple). Cela suggère que ce modèle obtient de très bons résultats sur une majorité d'exemples mais reste médiocre sur une queue d'exemples difficiles qui pèse davantage dans une moyenne par exemple que dans un F1 agrégé. Ce point mériterait d'être vérifié plus précisément, par exemple en traçant la distribution complète des F1 par exemple plutôt qu'en se limitant à la moyenne et aux dix pires cas.

Modèle	F1 global (seed 42)	F1 moyen par exemple
Pantagruel-B-1K	0.3425	0.3447
Pantagruel-B-14K	0.3502	0.3476
Pantagruel-L-14K	0.3586	0.3550
LeBenchmark-w2v-B-1k	0.3726	0.3693
LeBenchmark-w2v-L-7k	0.3793	0.3538

TABLE 2 – Comparaison entre le F1 global (agrégé sur l’ensemble du test) et le F1 moyen exemple par exemple.

4.1 Un exemple échoue systématiquement, quel que soit le modèle

Le rapprochement des dix pires exemples de chaque modèle fait apparaître un recouvrement important. L’exemple d’indice 66 figure parmi les dix pires exemples des cinq modèles, avec un F1 nul dans tous les cas. Le tableau 3 détaille les faux positifs et faux négatifs obtenus sur cet exemple pour chaque modèle.

Modèle	Faux positifs	Faux négatifs
Pantagruel-B-1K	5	1
Pantagruel-B-14K	4	1
Pantagruel-L-14K	4	1
LeBenchmark-w2v-B-1k	6	1
LeBenchmark-w2v-L-7k	4	1

TABLE 3 – Faux positifs et faux négatifs sur l’exemple d’indice 66, commun aux cinq modèles.

Sur cet exemple, tous les modèles prédisent entre quatre et six frontières en trop, pour un seul faux négatif à chaque fois. Le fait que l’échec soit partagé par des encodeurs de familles et de tailles différentes, avec un schéma d’erreur similaire (sur-segmentation), suggère que la cause n’est probablement pas liée à la représentation apprise par tel ou tel encodeur, mais plutôt à l’exemple lui-même : label de référence incomplet, audio contenant plusieurs pauses ou hésitations non annotées comme frontières, ou bruit acoustique particulier. Trois autres exemples (indices 35, 37 et 433) reviennent également dans les dix pires cas d’au moins trois modèles sur cinq, ce qui va dans le même sens.

Une prochaine étape utile serait d’écouter directement ces quelques exemples récurrents pour vérifier s’il s’agit d’un problème de labellisation automatique (pauses mal détectées par le système de génération des labels) ou d’un phénomène acoustique réel non prévu par le protocole d’annotation.

4.2 Les erreurs les plus fréquentes sont des sur-segmentations

En regroupant les dix pires exemples des cinq modèles (50 cas au total, avec répétitions), 33 cas sur 50 sont dominés par les faux positifs (plus de frontières prédites que de frontières de référence), contre 13 cas dominés par les faux négatifs et 4 cas à égalité. Le nombre total de faux positifs cumulés (152) est environ 1,8 fois supérieur au nombre total de faux négatifs cumulés (85) sur ces mêmes exemples.

Ce déséquilibre indique que, sur les cas les plus difficiles, les modèles ont davantage tendance à sur-segmenter (détecter des frontières supplémentaires non présentes dans la référence) qu’à manquer des frontières réelles. Cela pointe vers deux hypothèses non exclusives évoquées dans le rapport précédent, mais que l’analyse d’erreurs permet cette fois d’appuyer sur des cas concrets :

- les paramètres de détection de pics (prominence, distance minimale entre pics) sont peut-être trop permissifs, ce qui transforme de petites variations du signal continu en frontières prédites ;

- le bruit des labels automatiques (pauses détectées dans le signal) peut sous-estimer le nombre réel de frontières sur certains exemples (hésitations, reprises, bruit de fond confondu avec une pause), ce qui pénalise artificiellement des prédictions qui seraient en réalité correctes.

À l'inverse, l'exemple d'indice 650 (**Pantagruel-L-14K**, 0 faux positif, 7 faux négatifs) illustre le cas opposé : un exemple où le modèle ne détecte quasiment aucune des frontières attendues, probablement un audio plus long ou avec des frontières moins marquées acoustiquement.

5 Discussion

Ces résultats répondent directement aux deux remarques de mon encadrant. D'une part, la comparaison multi-seeds montre que le classement entre **LeBenchmark-w2v-B-1k** et **LeBenchmark-w2v-L-7k** observé la semaine précédente n'était pas robuste : c'est finalement le modèle large qui obtient le meilleur F1 en moyenne, et il est aussi le plus stable d'un seed à l'autre. Le cas de **Pantagruel-L-14K** montre à l'inverse qu'un bon résultat isolé peut correspondre à une seed favorable plutôt qu'à un avantage réel du modèle.

D'autre part, l'analyse d'erreurs, en se rapprochant des exemples concrets plutôt qu'en se limitant aux seules métriques agrégées, met en évidence qu'une partie des erreurs n'est pas propre à un encodeur mais partagée par tous les modèles sur les mêmes exemples, avec un même type d'erreur (sur-segmentation). Cela renforce l'hypothèse, déjà formulée la semaine précédente, que le bruit des labels automatiques constitue une limite importante du protocole actuel, indépendamment du choix de l'encodeur.

6 Conclusion

Le ré-entraînement sur trois seeds a permis de vérifier la robustesse des comparaisons entre modèles : **LeBenchmark-w2v-L-7k** est le modèle le plus performant et le plus stable en moyenne ($F1 = 0.3773 \pm 0.0025$), suivi de **LeBenchmark-w2v-B-1k** (0.3710 ± 0.0046) et de **Pantagruel-B-14K** (0.3544 ± 0.0042). L'analyse d'erreurs a par ailleurs permis d'identifier des exemples systématiquement mal segmentés par tous les modèles, ainsi qu'une tendance générale à la sur-segmentation sur les cas les plus difficiles.

6.1 Perspectives

Les prochaines pistes d'amélioration sont les suivantes :

- écouter et inspecter manuellement les exemples récurrents dans les pires cas (notamment l'indice 66) pour déterminer s'il s'agit d'un problème de labellisation ou d'un phénomène acoustique réel ;
- étudier l'effet des paramètres de détection de pics (prominence, distance minimale) sur le taux de faux positifs, en priorité sur les exemples sur-segmentés ;
- tracer la distribution complète des F1 par exemple (et pas seulement la moyenne et les dix pires cas) pour mieux caractériser l'écart observé entre F1 global et F1 moyen par exemple, en particulier pour **LeBenchmark-w2v-L-7k** ;
- étendre l'analyse multi-seeds à la sélection de checkpoint (validation loss vs F1 de validation), afin de vérifier si ce choix affecte aussi la variance observée ;
- envisager un nettoyage ou une pondération des exemples dont le label semble peu fiable, avant un futur ré-entraînement.