

Rapport hebdomadaire : extension de l'évaluation fine-tuning aux modeles LeBenchmark

TROMBATI Mohamed

Semaine suivante

1 Introduction

La semaine precedente, le travail portait principalement sur la mise en place d'une approche de fine-tuning pour la segmentation prosodique a partir d'embeddings extraits de modeles Pantagruel geles. L'objectif etait d'entrainer une tete de segmentation legere, appelee `ProsodicSegmentationHead`, afin de predire un score continu de frontiere prosodique pour chaque frame audio.

Cette semaine, le travail a consiste a etendre cette evaluation a de nouveaux encodeurs de la famille LeBenchmark, puis a realiser une evaluation finale des modeles sur le split de test. L'objectif etait de comparer les performances des representations Pantagruel et LeBenchmark dans le meme cadre experimental : meme jeu de donnees, meme generation de labels, meme tete de segmentation et memes criteres d'evaluation.

2 Rappel du systeme existant

Le pipeline conserve la meme structure que la semaine precedente. Les signaux audio issus de Common Voice FR sont d'abord convertis en embeddings par un encodeur audio pre-entraine et gele. Les embeddings sont ensuite sauvegardes dans un cache afin de separer l'extraction des representations de l'apprentissage supervise.

Les labels de segmentation sont construits automatiquement a partir des pauses detectees dans le signal audio. Pour tenir compte de l'incertitude temporelle autour des frontieres prosodiques, les labels ne sont pas binaires. Ils sont representes par des gaussiennes centrees sur les positions de frontieres.

La tete de segmentation utilise une architecture Conv1D suivie d'un BiLSTM. Le padding dynamique est gere par le `collate_fn`, et les positions de padding sont masquees dans la fonction de perte. Cette organisation permet de traiter des sequences audio de longueurs variables sans que les frames artificielles influencent l'apprentissage.

3 Changements effectues cette semaine

3.1 Ajout des modeles LeBenchmark

Le principal changement a ete l'integration de deux encodeurs LeBenchmark dans le protocole de fine-tuning :

- `LeBenchmark-w2v-B-1k`
- `LeBenchmark-w2v-L-7k`

Ces modeles ont ete ajoutes a la configuration afin d'etre traitees de la meme maniere que les modeles Pantagruel. Pour chaque modele, les embeddings ont ete extraits, les labels continus ont ete generes, puis une tete de segmentation a ete entraine.

3.2 Evaluation finale sur le split test

La semaine precedente, la comparaison portait surtout sur les performances de validation pendant l’entrainement. Cette semaine, une evaluation finale a ete realisee sur le split de test pour les cinq modeles :

- Pantagruel-B-1K
- Pantagruel-B-14K
- Pantagruel-L-14K
- LeBenchmark-w2v-B-1k
- LeBenchmark-w2v-L-7k

Cette evaluation permet d’obtenir une mesure plus representative de la generalisation des modeles, car elle est effectuee sur des donnees non vues pendant l’entrainement ni pendant la selection du checkpoint.

4 Resultats d’entrainement des modeles LeBenchmark

4.1 LeBenchmark-w2v-B-1k

Le modele **LeBenchmark-w2v-B-1k** montre une convergence rapide. La validation loss diminue fortement entre les premieres epoques, puis continue a s’ameliorer plus progressivement jusqu’a atteindre une meilleure valeur autour de 0.0169.

Le meilleur F1 de validation observe est de 0.3205 a l’epoque 12. Ce score est superieur aux meilleurs scores de validation obtenus la semaine precedente avec les modeles Pantagruel, qui se situaient autour de 0.30–0.31.

Epoch	Train Loss	Validation Loss	Validation F1
1	0.0850	0.0237	0.2876
2	0.0220	0.0195	0.3052
3	0.0197	0.0185	0.2987
5	0.0182	0.0175	0.3055
7	0.0175	0.0171	0.3166
9	0.0168	0.0169	0.3168
12	0.0160	0.0171	0.3205
14	0.0156	0.0169	0.3177

TABLE 1 – Evolution de l’entrainement du modele LeBenchmark-w2v-B-1k

4.2 LeBenchmark-w2v-L-7k

Le modele **LeBenchmark-w2v-L-7k** presente une progression plus lente au debut de l’entrainement. La premiere epoque donne un F1 de validation nul, ce qui indique probablement que les pics predits ne correspondent pas encore aux frontieres attendues avec les seuils d’evaluation utilises.

Le modele s’ameliore ensuite nettement et atteint une meilleure validation loss de 0.0170 a l’epoque 13. Le meilleur F1 de validation observe est de 0.3126 a l’epoque 10. Le modele large LeBenchmark reste donc competitif, mais il ne depasse pas le modele **LeBenchmark-w2v-B-1k**.

5 Evaluation finale sur le test set

Les resultats suivants correspondent a l’evaluation finale sur le split de test. Les metriques re-portees sont la precision, le rappel et le F1-score.

Epoch	Train Loss	Validation Loss	Validation F1
1	0.0941	0.0353	0.0000
2	0.0308	0.0224	0.2427
5	0.0204	0.0187	0.2794
7	0.0194	0.0186	0.2931
10	0.0180	0.0181	0.3126
12	0.0176	0.0178	0.2950
13	0.0176	0.0170	0.3079
18	0.0166	0.0190	0.2797

TABLE 2 – Evolution de l’entrainement du modele LeBenchmark-w2v-L-7k

Modele	Precision	Recall	F1-score
Pantagruel-B-1K	0.3398	0.3727	0.3450
Pantagruel-B-14K	0.3448	0.3687	0.3472
Pantagruel-L-14K	0.3517	0.3794	0.3550
LeBenchmark-w2v-B-1k	0.3606	0.3980	0.3695
LeBenchmark-w2v-L-7k	0.3488	0.3761	0.3536

TABLE 3 – Resultats finaux sur le split test

6 Analyse et comparaison

6.1 Comparaison avec les resultats de la semaine precedente

La semaine precedente, les meilleurs F1 de validation des modeles Pantagruel etaient proches les uns des autres, autour de 0.30–0.31. Le meilleur modele observe etait **Pantagruel-B-14K**, avec un F1 de validation de 0.3090.

Les resultats de cette semaine montrent deux evolutions importantes. D’abord, les scores de test des modeles Pantagruel sont plus eleves que les scores de validation rapportes precedemment. Par exemple, **Pantagruel-L-14K** atteint 0.3550 de F1 sur le test set. Ensuite, le modele **LeBenchmark-w2v-B-1k** obtient le meilleur resultat global avec un F1-score de 0.3695.

L’ecart entre le meilleur modele Pantagruel sur test (**Pantagruel-L-14K**, 0.3550) et le meilleur modele LeBenchmark (**LeBenchmark-w2v-B-1k**, 0.3695) est d’environ 0.0145 point de F1. Cet ecart reste modere, mais il est coherent avec les resultats de validation, ou **LeBenchmark-w2v-B-1k** obtenait deja le meilleur F1 observe.

6.2 Meilleur modele global

Le modele **LeBenchmark-w2v-B-1k** est le meilleur modele sur les trois metriques du test set :

- meilleure precision : 0.3606 ;
- meilleur rappel : 0.3980 ;
- meilleur F1-score : 0.3695.

Ce resultat indique que ce modele ne se contente pas de predire davantage de frontieres. Il ameliore a la fois la capacite a retrouver les frontieres attendues et la capacite a limiter les detections incorrectes.

6.3 Comportement des modeles Pantagruel

Parmi les modeles Pantagruel, **Pantagruel-L-14K** obtient le meilleur score de test avec un F1 de 0.3550. Ce resultat differe legerement de l’observation faite sur la validation, ou **Pantagruel-B-14K** semblait etre le meilleur compromis.

Cette difference suggere que le classement des modeles peut dependre du split utilise. Elle peut aussi indiquer que le modele large generalise mieux sur le test set, meme si son avantage n'etait pas clairement visible pendant l'entrainement.

6.4 Comportement des modeles LeBenchmark

Le modele `LeBenchmark-w2v-B-1k` depasse le modele `LeBenchmark-w2v-L-7k`, alors que ce dernier est plus grand. Cette observation confirme que la taille du modele n'est pas le seul facteur determinant pour cette tache.

Plusieurs hypotheses peuvent expliquer ce resultat. Le modele base peut produire des representations plus directement exploitables par une tete de segmentation legere. Le modele large peut aussi necessiter un reglage different des hyperparametres, notamment du learning rate, du dropout, de la loss ou des parametres de detection de pics.

7 Sources possibles des differences observees

7.1 Qualite et bruit des labels

La principale source de limitation reste probablement la qualite des labels. Les frontieres prosodiques sont construites automatiquement a partir des pauses detectees dans le signal audio. Elles ne correspondent donc pas toujours a des frontieres prosodiques ou linguistiques reelles.

Ce bruit peut limiter les performances maximales atteignables. Il peut aussi expliquer pourquoi les modeles plus grands ne dominent pas systematiquement : une capacite de representation plus importante ne compense pas necessairement des annotations imparfaites.

7.2 Detection des pics et seuils d'evaluation

Le F1 final depend fortement de la conversion des scores continus en frontieres discretees. Cette conversion repose sur des parametres comme la prominence des pics, la distance minimale entre deux pics et la tolerance temporelle utilisee pour faire correspondre prediction et reference.

Un modele peut produire un bon signal continu mais obtenir un F1 limite si les seuils de detection ne sont pas adaptes a la forme de ses sorties. Il serait donc utile de tester une recherche de seuils sur le split de validation avant l'evaluation finale sur test.

7.3 Difference entre validation loss et F1-score

Les checkpoints sont selectionnes a partir de la validation loss, alors que la comparaison finale repose sur le F1-score. Or ces deux criteres ne mesurent pas exactement la meme chose.

La loss mesure la proximite entre le signal predit et le label continu. Le F1 mesure la qualite des frontieres discretees apres detection de pics. Il est donc possible qu'une epoque avec une loss legerement moins bonne produise pourtant des pics mieux places et un meilleur F1.

7.4 Alignement temporel des representations

Les encodeurs ne produisent pas necessairement des embeddings avec la meme resolution temporelle. Les labels sont donc reprojetes sur un nombre de frames qui depend du modele. De petits decalages d'alignement peuvent avoir un impact important, car la tache consiste a detecter des evenements temporels fins.

7.5 Nature des representations pre-entrainees

Les modeles Pantagruel et LeBenchmark n'ont pas forcement ete pre-entraines avec les memes objectifs, les memes donnees ou les memes resolutions temporelles. Ces differences peuvent influencer la quantite d'information prosodique presente dans les embeddings.

Le bon resultat de **LeBenchmark-w2v-B-1k** suggere que ses representations contiennent des indices acoustiques utiles pour localiser les ruptures prosodiques.

7.6 Caracteristiques de Common Voice

Common Voice contient des enregistrements varies, avec des differences de locuteurs, de qualite audio, de bruit de fond et de debit de parole. Ces variations peuvent rendre la detection de pauses et de frontieres plus difficile.

Le contenu des splits train, validation et test peut egalement varier. Cela peut expliquer pourquoi certains modeles se comportent differemment entre la validation et le test.

8 Conclusion

Cette semaine a permis de completer l’etude menee la semaine precedente en ajoutant les modeles **LeBenchmark** et en realisant une evaluation finale sur le split test.

Les resultats montrent que tous les modeles fine-tunes obtiennent des performances relativement proches, mais que **LeBenchmark-w2v-B-1k** fournit le meilleur resultat global avec un F1-score de 0.3695. Parmi les modeles **Pantagrue1**, **Pantagrue1-L-14K** obtient le meilleur score de test avec un F1 de 0.3550.

Ces resultats confirment que la segmentation prosodique ne depend pas uniquement de la taille de l’encodeur. La qualite des representations temporelles, l’alignement entre embeddings et labels, les seuils de detection des pics et le bruit des annotations jouent un role important.

8.1 Perspectives

Les prochaines pistes d’amelioration sont les suivantes :

- optimiser les seuils de detection de pics sur le split de validation ;
- comparer la selection de checkpoint par validation loss et par F1 de validation ;
- analyser qualitativement des exemples audio pour identifier les faux positifs et faux negatifs ;
- tester differentes largeurs de gaussiennes pour les labels continus ;
- evaluer l’impact du nombre d’exemples d’entrainement ;
- verifier plus finement l’alignement temporel entre embeddings, labels et duree audio.